Bài toán: Giải quyết bài toán kỹ thuật dữ liệu cho một nền tảng giáo dục trực tuyến quy mô lớn, nơi dữ liệu thô bao gồm: luồng clickstream telemetry (web/mobile), tài liệu giảng dạy đa định dạng (video transcript, slide, PDF), nhật ký thay đổi trạng thái giao dịch (CDC từ PostgreSQL), và dữ liệu thực thi mã/bài nộp từ sandbox.

-> Cần biến các nguồn dữ liệu rời rạc, phi cấu trúc thành các kho dữ liệu phục vụ phân tích học tập (Learning Analytics), hệ thống gợi ý thích ứng và phát hiện nguy cơ bỏ học sớm.

Stakeholder và Business requirement:

Mã	Nhóm người dùng	Yêu cầu nghiệp vụ (Business Requirement)	Nhu cầu kỹ thuật dữ liệu tương ứng
BR 1	Người học (Learner)	Nhận thông báo khi có thay đổi quan trọng về khóa học như bài tập mới, deadline sắp đến hoặc nội dung được cập nhật	**Event-driven Notification Pipeline:** Phát hiện sự kiện từ hệ thống LMS qua message broker, áp dụng rule engine để lọc sự kiện và gửi notification theo thời gian thực.
BR 2	Người học (Learner)	Nhận gợi ý khóa học và bước học tiếp theo theo thời gian thực	Dual-branch Feature Pipeline: Batch feature (Spark) kết hợp Streaming session feature (Flink/Spark Streaming) qua Feature Store.
BR 3	Người học (Learner)	Nhận phản hồi chi tiết lỗi khi nộp bài tập lập trình/SQL	Decoupled Grading Ingestion: Hàng đợi đệm tải bài nộp, chuẩn hóa đầu ra kiểm thử có cấu trúc (stderr, test-case diff, runtime).
BR 4	Giảng viên (Instructor)	Phát hiện câu hỏi bài tập hoặc test case có tỷ lệ trượt bất thường	Aggregation Mart: Tổng hợp tỷ lệ vượt qua theo từng test case/câu hỏi để lọc đề bài bị lỗi logic hoặc quá khó.
BR 5	Cố vấn học tập (Advisor)	Nhận cảnh báo sớm học viên có	CDC & Stream Windowing: Đọc log thay đổi từ OLTP, tính điểm rủi ro trượt qua sliding

		nguy cơ bỏ dở khóa học	window và phát sinh cảnh báo (drop-out trigger).
BR 6	Quản trị viên (Admin/B2B)	Theo dõi tiến độ kỹ năng và tỷ lệ hoàn thành theo tổ chức	Lakehouse Medallion Pipeline: Chuẩn hóa telemetry (schema versioning), khử định danh (PII) và tổng hợp báo cáo tổ chức (min-cohort threshold).
BR 7	Giảng viên (Instructor)	Xem biểu đồ nhiệt (heatmap) tương tác video bài giảng	Telemetry Granular Aggregation: Tính toán mật độ play/pause/rewind trên từng mốc giây của video bài giảng.
BR 8	Giảng viên (Instructor)	Đồng bộ trạng thái, vô hiệu hóa Cache và làm mới Search Index khi nội dung khóa học thay đổi	**Engagement Trend Pipeline:** Tổng hợp dữ liệu hoạt động theo time window (đăng nhập, xem bài, làm bài, thảo luận), tính engagement score và phát hiện xu hướng giảm theo thời gian.

Datasource:

Luồng sự kiện Telemetry (Streaming & Semi-structured):

- *Nguồn:* Client web, Android, iOS (chuẩn hóa xAPI/Caliper hoặc schema nội bộ).
- *Đặc tính:* Lưu lượng lớn (high velocity), đến trễ hoặc sai thứ tự do thiết bị mobile offline tạm thời; payload dạng JSON.

Nhật ký thay đổi cơ sở dữ liệu (Transactional CDC):

- *Nguồn:* WAL/Replication log của PostgreSQL/MySQL (tiến độ học, nộp bài, điểm số).
- *Đặc tính:* Tuân thủ tính toàn vẹn thứ tự, tải ghi theo dòng (row-level stream), không ảnh hưởng tài nguyên truy vấn production.

Tài liệu học tập phi cấu trúc (Unstructured Corpus):

- *Nguồn:* Object Storage (transcript video từ CMS, slide PDF, bài tập thực hành).
- *Đặc tính:* Dữ liệu văn bản dài, đòi hỏi trích xuất bố cục, xử lý ranh giới đoạn (semantic chunking) và quản lý phiên bản nghiêm ngặt.

Nhật ký thực thi bài nộp (Structured Evaluation Logs):

- *Nguồn:* Sandbox execution worker (stdout, execution time, memory usage, test assertion status).

Solution architecture:

Data Ingestion: Apache Kafka (tiếp nhận clickstream & telemetry) kết hợp Debezium (CDC từ OLTP database).
Data Processing:

- *Streaming:* **Apache Flink** (xử lý stateful stream, tính toán windowing cho điểm rủi ro bỏ học và session features với độ trễ thấp).
- *Batch:* **Apache Spark** (tính toán feature dài hạn, chạy pipeline chunking/embedding quy mô lớn).

Data Management:

- *Lakehouse layer:* **Databricks / Delta Lake (hoặc Apache Iceberg)** trên Object Storage phục vụ lưu trữ phân tích tuân thủ ACID và time-travel.
- *Low-latency Serving layer:* **Cassandra** hoặc **Redis** (lưu trữ feature store trực tuyến và điểm rủi ro học viên).
-

Event & Notification Layer

- **Kafka** tiếp tục đóng vai trò event bus cho các event như `assignment_created`, `deadline_approaching`, `course_updated`.
- **Notification Service** – consume notification events và gửi Push Notification / In-app Notification / Email.
- Có thể dùng **Redis** để lưu notification state, rate limiting và deduplication.